

Utilizzo di metodi ensemble per valutare l'efficacia di campagne marketing

Gabriele Senatore^{1,2}

¹Dipartimento di Scienze economiche e statistiche, Università degli Studi di Salerno

²Corso di laurea in Scienze statistiche per la finanza

Abstract

Questo studio analizza l'efficacia dei modelli di apprendimento supervisionato nelle campagne marketing. Attraverso il confronto tra un modello benchmark (CART) e tecniche di ensemble (Bagging, Random Forest e AdaBoost), il lavoro dimostra come l'aggregazione di modelli complessi permetta di superare i limiti predittivi del singolo albero decisionale. La valutazione, basata su metriche robuste quali PR-AUC e MCC (Matthews Correlation Coefficient), evidenzia la superiorità dell'AdaBoost in termini di potere discriminante (AUC 0.88). Tuttavia, l'implementazione di una procedura di *threshold tuning* rivela che il Random Forest offre il miglior compromesso operativo per il business, garantendo una sensibilità del 69.7% con una specificità superiore al 86%. I risultati confermano che variabili legate allo storico delle interazioni passate e all'ultima data d'acquisto costituiscono i driver primari per la massimizzazione del tasso di conversione delle campagne.

1 Introduzione

Nel moderno scenario del Database Marketing, la capacità di prevedere il comportamento dei consumatori è il principale fattore di ottimizzazione dei costi. Questo progetto analizza un dataset di oltre 2.200 clienti con l'obiettivo di sviluppare un modello predittivo capace di identificare i profili più propensi ad aderire a una campagna promozionale. Attraverso l'uso di algoritmi di Statistical Learning — tra cui Random Forest, Bagging e Boosting — l'analisi mira a massimizzare il tasso di conversione, riducendo al contempo lo spreco di risorse su segmenti di clientela non reattivi. Nel lavoro sono state integrate tecniche di feature engineering e allo stesso tempo tecniche per valutare i risultati quando si lavora con dataset che presentano uno sbilanciamento della variabile di risposta.

2 Dataset e Feature Engineering

Il dataset [1], è composto originalmente da 2240 osservazioni e 29 variabili. Dopo una fase di pre processing dei dati (rimozione dei valori nulli e duplicati, selezione delle variabili

utili e feature engineering) abbiamo un dataset finale con 2212 osservazioni e 23 variabili. Qui di seguito una tabella riepilogativa delle variabili utilizzate:

Table 1: Sintesi delle variabili utilizzate nel modello predittivo

Categoria	Variabile/i	Descrizione e Note
Target	Response	Variabile binaria (Si/No): adesione all'ultima campagna marketing.
Socio-Dem.	Income, Education, Marital, Kid/Teenhome	Profilo demografico, reddito annuo familiare e composizione del nucleo (bambini/adolescenti).
Comportamento	Mnt[Products]* Recency, Complain	Importo speso in 2 anni per: Vini, Carne, Pesce, Frutta, Dolci e prodotti Gold. Giorni dall'ultimo acquisto e presenza di reclami.
Canali	Num[Channel]Purch*	Numero di acquisti tramite Web, Catalogo e Negozio; visite mensili al sito e acquisti con sconti.
Feature	total_acc_cmp	Somma delle 5 campagne precedenti accettate (Indice di fedeltà).
Engineering	Customer_Tenure	Giorni trascorsi dall'iscrizione del cliente ad oggi.
	Total_Purchases	Volume totale degli acquisti effettuati (tutti i canali).
	Web_Conv_Rate	Rapporto tra acquisti online e visite effettuate.

*Per la descrizione dettagliata delle variabili originali si rimanda alla documentazione ufficiale [1].

La variabile target del progetto (Response) è distribuita nel seguente modo:

No	Sì
0.8504	0.1496

Table 2: Frequenze osservate variabile Response

Si può notare quindi come sia presente uno sbilanciamento e questa informazione sarà importante nella valutazione dei modelli.

2.1 Feature engineering

Al fine di migliorare la capacità predittiva dei modelli e sintetizzare in modo più informativo le caratteristiche dei clienti, è stata condotta una fase di feature engineering sui dati originali. L'obiettivo principale di questa fase è stato quello di costruire variabili derivate in grado di catturare in modo più efficace il comportamento dei clienti rispetto alle campagne di marketing e alle loro abitudini di acquisto.

In primo luogo, le cinque variabili binarie AcceptedCmp1, AcceptedCmp2, AcceptedCmp3, AcceptedCmp4 e AcceptedCmp5, che indicano se il cliente ha accettato l'offerta in ciascuna delle precedenti campagne, sono state aggregate in un'unica variabile denominata

`total_acc_cmp`. Questa nuova variabile rappresenta il numero totale di campagne precedenti a cui il cliente ha aderito e costituisce una misura sintetica del livello di reattività del cliente alle iniziative di marketing. Si ipotizza che clienti con valori di `total_acc_cmp` maggiori di zero siano più propensi ad accettare un'offerta anche nell'ultima campagna. Successivamente, la variabile temporale `Dt_Customer`, che indica la data di acquisizione del cliente, è stata trasformata in una misura quantitativa di anzianità. In particolare, è stata costruita la variabile `Customer_Tenure`, definita come il numero di giorni trascorsi tra la data di acquisizione e la data di riferimento dell'analisi. Questa trasformazione consente di valutare l'effetto della durata della relazione cliente-azienda sul comportamento di risposta alle campagne. È stata inoltre creata la variabile `Total_Purchases`, ottenuta come somma del numero di acquisti effettuati tramite canali web, catalogo e punto vendita fisico. Tale variabile fornisce una misura complessiva dell'intensità di acquisto del cliente, indipendentemente dal canale utilizzato. Infine, per analizzare l'efficacia del canale online, è stato introdotto il `Web_Conversion_Rate`, definito come il rapporto tra il numero di acquisti effettuati sul web e il numero di visite mensili al sito. Nei casi in cui il numero di visite fosse nullo, il tasso di conversione è stato posto pari a zero, evitando problemi di divisione per zero. Questa variabile permette di distinguere tra clienti che visitano frequentemente il sito senza acquistare e clienti con un'elevata propensione alla conversione. Nel complesso, le variabili derivate ottenute tramite il processo di feature engineering consentono di rappresentare in modo più informativo il comportamento dei clienti.

3 Metodi

In questa sezione vengono descritti sinteticamente gli algoritmi di apprendimento supervisionato utilizzati per la classificazione della variabile target *Response*.

3.1 CART (Classification and Regression Trees)

Il CART è un metodo basato su alberi decisionali che partiziona ricorsivamente lo spazio delle feature. In questo studio, il CART viene utilizzato come **benchmark** (modello base) per valutare il guadagno prestazionale offerto dai metodi ensemble più complessi. Per evitare l'overfitting, l'albero è stato sottoposto a potatura (*pruning*) ottimizzando il parametro di complessità (*cp*) tramite Cross-Validation.

3.2 Bagging (Bootstrap Aggregating)

Il Bagging è una tecnica di ensemble progettata per ridurre la varianza di stimatori instabili come gli alberi decisionali. Il metodo genera B campioni di *bootstrap* (estrazione con reinserimento) dal dataset originale e addestra un albero su ciascuno di essi in parallelo. La classificazione finale è ottenuta aggregando le previsioni dei singoli alberi tramite votazione a maggioranza (consensus), garantendo una maggiore stabilità e robustezza rispetto al singolo albero CART.

3.3 Random Forest

Il Random Forest è un'evoluzione del Bagging che mira a decorrelare gli alberi. Oltre al campionamento bootstrap delle osservazioni, l'algoritmo introduce una selezione casuale di un sottoinsieme di variabili candidate (m_{try}) ad ogni nodo di split. Questo accorgimento riduce la correlazione tra gli alberi prodotti, abbattendo ulteriormente la varianza dell'errore. Nel modello finale, il parametro m_{try} è stato oggetto di tuning specifico.

3.4 AdaBoost (Adaptive Boosting)

A differenza dei metodi precedenti che operano in parallelo, l'AdaBoost utilizza un approccio sequenziale. L'algoritmo addestra una serie di classificatori deboli in successione: ogni nuovo modello si concentra maggiormente sulle osservazioni classificate erroneamente dai modelli precedenti, assegnando loro un peso maggiore. Questo processo iterativo mira a ridurre sia il bias che la varianza, costruendo un classificatore finale "forte" come combinazione pesata dei classificatori deboli.

4 Metodi di valutazione

Per valutare le prestazioni dei modelli stimati, si è utilizzato un partizionamento dei dati, rispettivamente l'80% per la fase di addestramento e il restante 20% per la fase di validazione. La fase di addestramento è stata utile per la selezione degli iperparametri mentre la fase di validazione è servita a valutare le prestazioni dei modelli addestrati su dati out of sample.

Dato che il dataset risulta essere sbilanciato rispetto alla variabile target (**Response**), come menzionato precedentemente, la valutazione non è stata fatta considerando solo il misclassification rate:

$$\text{Misclassification Rate} = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(\hat{y}_i \neq y_i)$$

Invece, la valutazione si basa sugli elementi della **Matrice di Confusione**, definita come segue considerando la classe "*Si*" come Positiva (*P*) e la classe "*No*" come Negativa (*N*):

- **True Positive (TP)**: Clienti che hanno accettato l'offerta correttamente classificati come tali.
- **False Negative (FN)**: Clienti che hanno accettato l'offerta erroneamente classificati come non interessati.
- **True Negative (TN)**: Clienti che non hanno accettato l'offerta correttamente classificati.

- **False Positive (FP):** Clienti che non hanno accettato l'offerta erroneamente classificati come interessati.

Sulla base di queste definizioni, sono state adottate le seguenti metriche:

- **Sensitivity (o Recall):** Rappresenta la capacità del modello di individuare correttamente tutti i clienti che hanno risposto positivamente alla campagna. È la metrica prioritaria per minimizzare i falsi negativi.

$$\text{Sensitivity} = \frac{TP}{TP + FN}$$

- **Specificity:** Misura la capacità del modello di identificare correttamente i clienti che non sono interessati all'offerta.

$$\text{Specificity} = \frac{TN}{TN + FP}$$

- **F1-Score:** È la media armonica tra Precision e Recall. È stata utilizzata come metrica obiettivo per l'ottimizzazione della soglia decisionale (t_{opt}), in quanto penalizza valori estremi di una delle due metriche.

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

- **Matthews Correlation Coefficient (MCC):** Considerato una delle metriche più robuste per dataset sbilanciati, restituisce un valore tra -1 e +1, dove +1 indica una predizione perfetta.

$$\text{MCC} = \frac{(TP \cdot TN) - (FP \cdot FN)}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

Successivamente, per confrontare i modelli in modo indipendente rispetto alla soglia di classificazione standard, quindi 0.5, sono state analizzate due curve [2]:

- **Curva ROC:** Utilizzata per valutare la capacità discriminante generale (AUC-ROC). Tuttavia, in dataset sbilanciati, la ROC può risultare eccessivamente ottimistica poiché la Specificity (tasso di veri negativi) tende a dominare a causa dell'alto numero di negativi;
- **Curva Precision-Recall:** È stata adottata come strumento principale di diagnosi, dove $\text{Precision} = \frac{TP}{TP + FP}$. A differenza della ROC, la curva PR non considera i "Veri Negativi" e si concentra esclusivamente sulla classe positiva. Come evidenziato in letteratura, un valore alto di AUC-ROC non implica necessariamente un buon modello per la classe minoritaria, mentre la PR-AUC offre una visione più onesta delle performance sui casi rari (i clienti che accettano l'offerta).

Infine, una volta selezionati i modelli migliori, si è ricercato una soglia ottimale nel seguente modo:

1. Sono state calcolate le probabilità predette mediante cross validation usando il set di addestramento;
2. È stata iterata una ricerca della soglia ottimale (t_{opt}) che massimizzasse l'F1-Score;
3. Tale soglia è stata poi applicata al Validation Set per la classificazione finale.

5 Risultati e discussioni

Il primo modello che andiamo a considerare è un CART potato (pruned). Tra tutti i modelli, per costruzione questo è l'unico che ci consente di avere una rappresentazione grafica di come avviene il processo decisionale. Una volta individuato il parametro di cost complexity ottimale, in termini di accuratezza previsiva, mediante cross validation, il grafico è il seguente:




Figure 1: CART(pruned) 13 nodi

Dal grafico dell'albero si può notare come il nodo radice è rappresentato dalla variabile **total_acc_cmp**, indicando che essa risulta essere la più informativa nel ridurre le due classi. Altre variabili importanti nella determinazione delle due classi risultano essere **Recency** e **Customer_Tenure** che indica il numero di giorni passati dall'ultimo acquisto e il numero di giorni trascorsi dall'iscrizione del cliente ad oggi. Possiamo notare come il nodo all'estrema sinistra sia il più consistente e rientrano gli individui che in passato non hanno accettato nessuna campagna e sono meno "anziani". Qui la probabilità di accettare è solo il 5%. Rappresenta un gruppo vasto ma meno profittevole. Mentre il nodo all'estrema

destra mostra come, se l'ultima interazione è recente (meno di 21 giorni), il modello prevede "Si" con una probabilità del 80%. In questo nodo, seppure di modeste dimensioni, si trovano clienti che sono potenzialmente propensi a rispondere ad una campagna.

Un altro dei modelli utilizzati è stato il Random Forest, anche in questo caso mediante cross validation si è scelto il numero di variabili ottimale, in termini di accuratezza, che vengono prese casualmente per la stima del modello. In questo caso si è optato per 5 variabili.




Figure 2: Random Forest - Accuratezza al variare di *mtry*

L'ultimo modello utilizzato è stato Adaboost, anche in questo caso si è individuato il numero di iterazioni ottimale mediante cross validation. Ottenendo una stabilizzazione dell'errore a 280 iterazioni (si veda grafico seguente: linea verticale tratteggiata blu).




Figure 3: Adaboost - Performance plot: train (linea nera) e test error (linea verde) (stime CV).

5.1 Tabella riepilogativa dei risultati

Di seguito, illustro i principali risultati ottenuti:

Modello	MCR	Sensitivity (TPR)	Specificity (TNR)	AUC	AUC-PR
Cart pruned	0.1199	0.4091	0.9627	0.7803	0.4790
Bagging	0.1222	0.4091	0.9601	0.8426	0.5520
Random Forest	0.1131	0.3636	0.9787	0.8426	0.5744
Adaboost	0.1018	0.4545	0.9760	0.8811	0.6340

Table 3: Confronto delle prestazioni dei modelli di classificazione

Dalla tabella si può notare come tutti i metodi ensemble superino il metodo benchmark CART in termini di potere discriminante (AUC) e precisione sulla classe minoritaria (AUC-PR). In particolare, l'AdaBoost si distingue come il modello più performante, raggiungendo un'AUC di 0.88 e un'AUC-PR di 0.63. Considerando anche che la prevalenza della classe positiva in questo caso è solo il 15% il valore di 0.63 dell'AUC-PR di Adaboost è significativo in quanto il modello è oltre quattro volte più efficace di una scelta casuale nell'identificare i potenziali aderenti alla campagna.

Nonostante l'elevata *Specificity* (prossima al 98% per quasi tutti i modelli), la *Sensitivity* risulta insoddisfacente, oscillando tra il 36% e il 45%. Questo accade perché la soglia di classificazione standard ($t = 0.5$) tende a favorire la classe maggioritaria in dataset sbilanciati.

5.2 Threshold Tuning

In seguito alle precedenti considerazioni, appare evidente che l'utilizzo della soglia standard di 0.5 sia conservativo. Per massimizzare l'efficacia della campagna marketing, si rende necessaria una procedura di **Threshold Tuning**. L'obiettivo sarà quello di individuare una soglia ottimale che permetta di sacrificare una piccola quota di *Specificity* in favore di un incremento della *Sensitivity*, ottimizzando così il bilanciamento tra precision e recall attraverso la massimizzazione dell'F1-Score.

I modelli scelti in questa fase sono i due che hanno ottenuto valori più elevati di AUC-PR nello specifico Random Forest e Adaboost. Per entrambi i modelli, è stata effettuata una ricerca della soglia t capace di massimizzare l'F1-Score. Questo approccio permette di non focalizzarsi solo sull'errore complessivo, ma di trovare il punto di equilibrio ideale. Le soglie ottimali individuate sono:

- **Random Forest:** $t_{opt} = 0.25$
- **AdaBoost:** $t_{opt} = 0.41$

L'applicazione delle nuove soglie ha prodotto un cambiamento nel profilo di performance dei modelli. La tabella seguente mette a confronto i risultati del Random Forest e di AdaBoost con la soglia ottimale:




Figure 4: Confronto grafico F1 su validation set al variare della soglia per i due modelli

Table 4: Confronto delle prestazioni dopo il Threshold Tuning

Modello	Sensitivity	Specificity	F1-Score	MCC
AdaBoost	0.4696	0.9627	0.5585	0.5096
Random Forest	0.6969	0.8670	0.5679	0.4874

Si evince dalla tabella come i valori di sensitività siano migliorati rispetto all'utilizzo della soglia standard e come ci aspettavamo leggermente peggiorati per quanto riguarda la specificità. Quindi i modelli post threshold tuning risultano essere maggiormente bilanciati.

In conclusione, sebbene l'AdaBoost avesse mostrato l'AUC e la PR-AUC più alta, il Random Forest con soglia ottimizzata si dimostra lo strumento più utile per individuare individui potenzialmente interessati a rispondere ad una campagna di marketing. Tuttavia AdaBoost ha avuto performance maggiori nell'individuare clienti realmente non interessati.

5.3 Variable importance

Infine per comprendere quali fattori guidino la propensione dei clienti ad aderire alla campagna marketing, è stata analizzata l'importanza delle variabili per i due modelli principali. Come si può immaginare per la costruzione dei due modelli, Adaboost si concentra su meno variabili che però risultano essere più rilevanti per correggere gli errori delle iterazioni precedenti, mentre il Random Forest presenta una distribuzione di variable importance più uniforme. Tale comportamento è dovuto alla tecnica del *bagging*: ad ogni split di ogni albero viene considerato solo un sottoinsieme casuale di m_{try} variabili. Come si può evincere dai grafici le variabili che risultano essere più importanti sono: **Total_Acc_Cmp**, **Customer_Tenure**, **Recency**.




Figure 5: VIP Adaboost




Figure 6: VIP Random Forest

6 Conclusioni

Il presente lavoro ha permesso di sviluppare un metodo predittivo per il supporto alle decisioni di marketing. L'analisi comparativa ha confermato che i metodi ensemble, pur richiedendo uno sforzo computazionale maggiore e una perdita di interpretabilità visiva diretta, forniscono una precisione significativamente più elevata rispetto ai modelli tradizionali.

Nel progetto è emersa l'inadeguatezza della soglia di classificazione standard (0.5) in contesti sbilanciati. Solo attraverso l'ottimizzazione della soglia decisionale è stato possibile trasformare modelli statisticamente accurati in strumenti utili al business, capaci di intercettare una quota significativa di clienti interessati che altrimenti sarebbero stati ignorati.

Dal punto di vista strategico, l'importanza di variabili come *Total_Acc_Cmp*, *Recency*, *Customer_Tenure* suggerisce all'azienda di adottare una politica di segmentazione basata sulla fedeltà comportamentale.

Infine, mentre il presente lavoro si è focalizzato sull'ottimizzazione della soglia decisionale (threshold tuning), sviluppi futuri potrebbero esplorare l'integrazione di tecniche di resampling (come l'over sampling della classe minoritaria o l'under sampling della maggioritaria). Questo permetterebbe di confrontare l'efficacia del ribilanciamento dei dati rispetto alla regolazione della soglia nel migliorare la sensibilità del modello.

References

- [1] Rod Saldanha. Marketing campaign. <https://www.kaggle.com/datasets/rodsaldanha/arketingcampaign/data>, 2021. Accesso effettuato il: February 3, 2026.
- [2] Alaa Tharwat. Classification assessment methods. *Applied Computing and Informatics*, 17(1):168–192, 2018.